合作

内容

和11年

学习 > Big data and analytics

ローココニア・エンコンコンファインコンフ

商业保险理赔案例

IBM SPSS 软件家族预测分析模型的商业应用初探,第2部分

斯第SPSS Statistics 线性回归模型分面定過與過程的解释

使用 ALM 进行线性回归分析

梁栋, 葛曦, 和杨继辉 预测和输出模型日发布

总结

相关系列内容:

评^论十 此内容是该系列 5 部分中的第 2 部分: **IBM SPSS 软件家族预测分析模型的商业应用初探**

IBM SPSS 软件家族预测分析模型的商业应用补

Statistics 和 Modeler 作为 IBM SPSS 软件家族中重要的成员,是专业的科学统计、数据挖掘分泛的特点。其核心组成部分——预测分析模型,不仅是软件功能实现的关键,同时也是软件应序

Statistics 中的模型侧重于统计分析技术,而 Modeler 则侧重于数据挖掘技术。它们都依据现象算法,来预测用户所关注信息的未来值。Statistics 和 Modeler 提供众多的预测模型,这使得它如超市商品如何摆放可以提高销量;分析商场营销的打折方案,以制定新的更为有效的方案;1推出新的保险品种等等,具有很强的商业价值。

Statistics 和 Modeler 产品中含有大量基于高级数学统计算法的预测模型,为了保证算法的严密需要许多详细的参数设定,这样就要求用户具有一定的统计专业知识,只有理解预测模型中的步力有可能结合结果做出正确的决策判断;另外,为了满足不同行业用户的需求,Statistics 和 M 同的范畴,即使专业用户也很难了解所有模型,从而挑选出最适合他们应用的模型。

合作

商业保险理赔案例

下面,我们将会陆续给大家介绍 IBM SPSS 软件家族中的 Statistics 和 Modeler 包含的典型预测 线性回归模型简介

商业保险理赔案例

用 Statistics 进行数据预处理

总结

这里我们主要研究和固定资产相关的理赔案例。理赔案例数据的主要变量信息如表 1 所示。其程夫主题 连续型变量,测量尺度为名义测量或有序测量的变量是离散型变量。

评论

表 1. 固定资产理赔案例数据的主要变量信息

字段名	含义	类型
claimid	理赔案例 ID	字符串
incident_date	事故发生日期	日期
claim_type	理赔类型	数值
uninhabitable	固定资产是否不易居住	数值
claim_amount	理赔金额(千元)	数值
fraudulent	是否为欺诈索赔	数值
policyid	保险单 ID	字符串

合作

policy_date	投保日期	日期
概览overage	保险责任范围金额 (千元)	数值
deductible	可扣除金额	数值
的业体应连师系例 townsize 线性回归模型简介	居住城镇大小	数值
gender	性别	数值
用 Statistics 进行数据预处理 dob 使用 AI M 讲行线性同归分析	出生日期	日期
edcat	受教育程度	数值
^总 j ob_start_date	开始工作时间	日期
retire	是否已退休	数值
income	家庭收入(千元)	数值
marital	婚姻状况	数值
reside	家庭成员人数	数值
occupancy_date	开始居住日期	日期
primary_residence	固定资产是否作为主要住所	数值

线性回归模型是一个应用广泛的模型分析方法,对解决这类问题非常合适。IBM SPSS Statistic 析和预测软件,它提供了十分强大的线性回归分析功能。本文将介绍线性回归模型的基本概念,新的"自动线性建模"功能来解决这个商业案例。

线性回归模型简介

合作

网器我们用变量来描述客观存在的事物,那么掌握变量(事物)间的内在规律并借以指导我们的关系可以称为确定性的关系,比如销售额 y 与销售量 x 之间的关系可以表示为 y=p*x(p 是商 概率能用这种确定性的函数来表达,比如:工资收入与教育程度的关系,健康程度与年龄的关系。我们需要从以往的大量数据当中,通过统计分析方法来确定他们之间的关系,并用适当的

用 Statistics 进行数据预处理
$$\hat{Y} = b_0 + b_1 x_1 + b_2 x_2 + ... + b_n x_n$$
 (1) 使用 $\mathbf{Ab_1} \mathbf{Ab_2} \mathbf{Ab_3} \mathbf{Ab_4} \mathbf{Ab_4} \mathbf{Ab_4} \mathbf{Ab_5} \mathbf{Ab_5$

建立线性回归模型的主要目标就是通过统计方法对回归系数进行参数估计,确定上述线性表达: 种分析,获取有价值的信息。

线性回归分析的基本步骤

通常来说,和其他统计分析与数据挖掘方法类似, 线性回归分析包括建立模型、模型评价和利式建模前,有时需要对数据进行预处理,我们将在后面进行介绍。

我们可以从样本数据出发,利用回归分析确定变量间的线性表达式,即用统计方法估计出线性。这就是建立模型的过程。之后,我们可以对这个线性表达式进行可信程度的统计检验,并评价是步的分析,寻找出在影响因变量的多个自变量中,哪些自变量对因变量的影响更为显著,哪些些都是模型评价的过程。然后,我们可以将这个关系表达式运用到新的数据集上,在知道所有是达式计算出因变量的取值,并利用统计方法评价预测值的精确程度,这就是利用已经建立好的是

传 IBM 分析与预测解决方案的重要组成部分,IBM SPSS Statistics 是一款面向商业用户、数员等具有不同知识背景的用户的、综合性的、易于使用的科学统计和预测分析工具。其操作简 概览一直以来就被广泛使用。

用 Statistics 进行数据预处理

用·Statistics 进行数据预处理

预测和输出模型

遵论. 数据预处理示例

	incident_date	incident_date_months	income	income_transformed	edcat	edcat_transformed
2301	7/26/2008	-34.899436459046314	33	33.0000000000000	2	
2302	1/12/2008	-41.334742565974601	186	174.5880023106965	4	
2303	1/24/2008	-40.967542398861493	1385	174.5880023106985	4	
2304	9/22/2008	-32.9978055365427	47	47.0000000000000	- 1	
2305	7/31/2008	-34.738026846147996	150	150.0000000000000	3	
2306	10/24/2008	-31.966687961061677	33	33.0000000000000	5	
2307	2/14/2008	-40.272200927827214	26	26.0000000000000	2	
2308	7/15/2008	-35.258575176819527	65	66.0000000000000	4	
2309	9/18/2008	-33.145398509392351	25	25.00000000000000	2	
2310	8/5/2008	-34.586759629644841	38	38.0000000000000	2	
2311	11/30/2008	-30.747294471062439	32	32.0000000000000	6	
2312	4/27/2008	-37.852647349608333	45	45.0000000000000	- 1	
2313	9/3/2008	-33.616734732679291	101	101.0000000000000	4	
2314	7/20/2008	-35,093136360179479	20	20.0000000000000	2	
2315	4/12/2008	-38.352508936040763	43	43.0000000000000	4	
2316	8/9/2003	-34.436211879230356	111	111.0000000000000	2	
2317	3/28/2008	-38.863739067609707	38	38.0000000000000	. 1	
2318	8/1/2003	-34.719785154764622	87	87.0000000000000	2	
2319	6/16/2008	-36.216217202829114	57	57.0000000000000	3	
2320	2/22/2008	-39.998549319339872	123	123.0000000000000	- 1	
2321	10/11/2008	-32.383106319872233	26	26.0000000000000	2	

我们可以在 Statistics 中手动进行数据预处理,图 1 显示了本商业实例中的部分数据在预处理前date(事故发生日期)的原始数据格式是"月 - 日 - 年",我们必须将它们转换成一个数值才能设是将日期数据转换为距离某参考日期的月份数目。在本例中我们选择当前日期为参考日期,于数。第三列 income(家庭收入)当中存在一些离群值,比如第 2303 行当中的收入 1385(千)模型不被这些数量不多但很影响平均值的数据所破坏,偏离真实的拟合曲线(或直线),需要是

合作

行归并,以使其与目标变量的关联最大化,在本例当中,发现高中以上水平四个类别的理赔案(果是只有两个类别,即"高中未毕业"与"高中以上水平",用 0 和 1 表示,如第六列所示。

融就istics 软件当中有一个自动预处理模块,即 ADP,其全称为 Automatically prepare data(l进行建模之前,可以选择预先执行 ADP,以提高数据的质量。这个过程在后台被执行,使用者真实量名会作品面增加一个"_transformed"后缀。

商业保险理赔案例

使用 ALM 进行线性回归分析

Statistics 的线性回归分析模块简介

使用isFo於潘崎珍博pwise 方法建立线性回归模型

使用 ALM 进行线性回归分析

阌纶. ALM 对话框 - 设置变量

合作

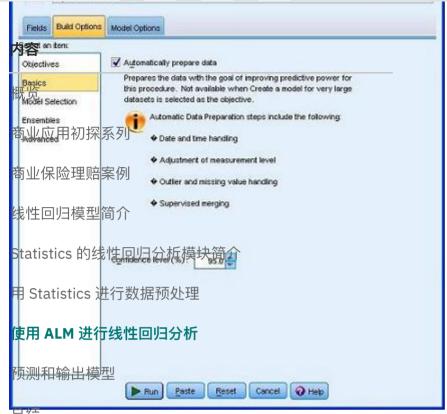


既然是要分析和预测理赔金额,我们当然选择 Cost of claim in thousands(理赔金额(千元)) 页当中,把该变量选入到 Target(目标)文本框当中。像理赔案例 ID、是否为欺诈索赔和保险 许安的关系不大,被留在左边的文本框当中,先不予考虑。剩下的变量就统统作为自变量,选入到 输入))文本框当中。

我们打开名为 Build Option (构建选项) 的 Tab 页, 如图 3 所示:

图 3. ALM 对话框 - 设置自动数据准备

合作



选择 Basics(基本选项)子页面,可以看到默认选择了 Automatically prepare data 选项,这种主题数据进行预处理。

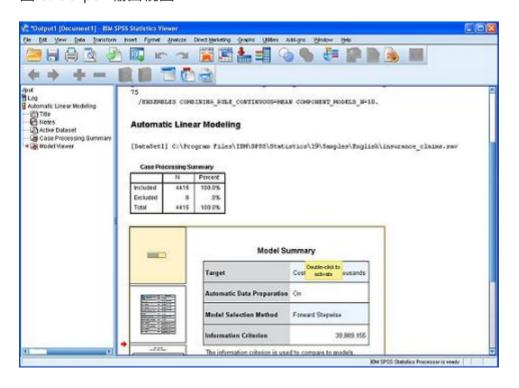
图 4. ALM 对话框 - 设置信息选择方法

合作



在类型。I Selection method(信息选择方法)中默认选择了 Forward Stepwise(前向逐步)方 Selection(前向逐步选择)区域当中的 Criteria for entry/removal(输入 / 删除标准)下拉框中 AICC(信息准则(校正的 Akaike))"、"F Statistics(F 统计)"、"Adjusted R2(调整后的 I Criterion(过度拟合防止标准(ASE))"几种判断标准。默认选择"信息准则 AICC"。我们不适行)按钮,可以看到一个新的窗口被打开,这就是用于显示建模结果的 Output(输出)视图。

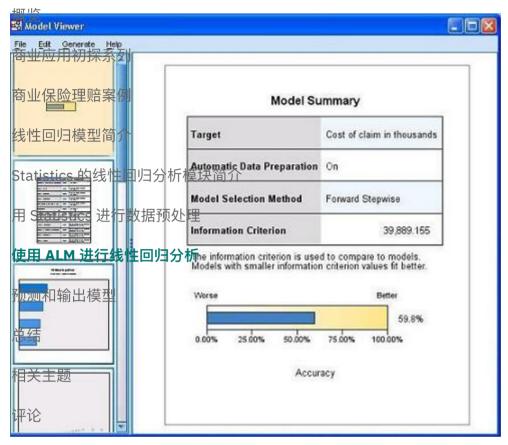
图 5. Output 输出视图



合作

Viewer(模型浏览器)。它提示用户可以通过双击激活它。我们双击它,打开模型浏览器,如

内容 图 6. 模型概要视图

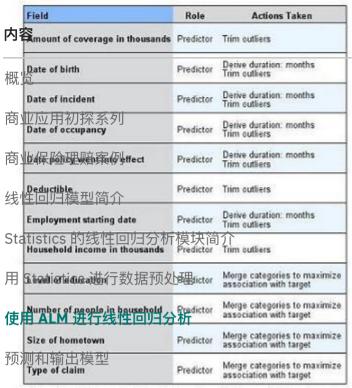


模型浏览器首先给我们展示的是图 6 当中的 Model Summary(模型概要)视图。从中我们可以名称是"理赔金额",而且"自动数据准备"功能被设置为"开"。而 Model Selection Method(信息Stepwise。而 Information criterion(信息准则)的取值是 39.889,我们可以用这个值对本模较。

我们从模型显示器左边较小的示意图中, 打开第二张图: "自动数据准备", 如图 7 所示:

图 7. 自动数据准备视图

合作



نظر لله eriginal field name is X, then the transformed field name is X_transformed.

The original field is excluded from the analysis and the transformed field is included instead.

對故规Action Taken 一列的说明文字中看到: Date of incident(事故日期),Date of Occupa 被转换成距离参考日期的月份数。变量 Household income in thousands(家庭收入(千元))。Level of education(教育水平)的类别也被合并,使其和目标变量的关联最大化。 让我们打开建汇总)视图。如图 8 所示:

图 8. 模型构建汇总视图

合作

Target: Cost of claim in thousands

囚	谷
	- 1

	Step						
概览	1	2	3	4			
Information Criterion 商业应用初探系列	42,512.907	40,663.053	39,890.379	39,889.155			
claim_type_transformed 商业保险 理赔案例	✓	✓	✓	✓			
coverage_transformed		✓	✓	✓			
线性 回 過模型简介 uninhabitable			✓	1			
Statistics 的线性回归分析模块 townsize_transformed	央简介			✓			

用 Stantistics 油布娄納福源处理ward Stepwise using the Information Criterion. A checkmark means the effect is in the model at this step.

使用 ALM 进行线性回归分析

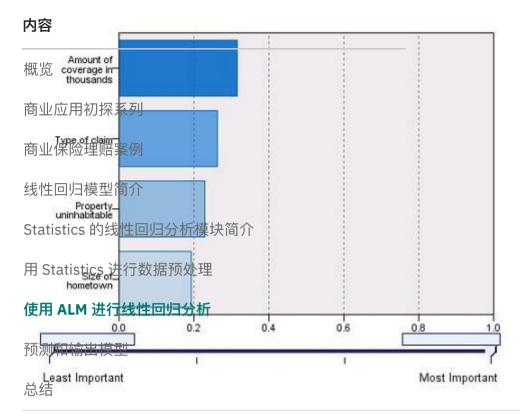
可以看到,其有 4 个自变量被选入到最终的模型,如图第 4 列所示,它们是"理赔类型"、"保险 恋易居住"和"居住城镇大小"。这些变量在模型当中被称之为 Effect(效应)。Forward Stepwi 视图中可以看出,迭代过程总共有 4 步,变量"理赔类型"在第一轮迭代中就被选入模型,变量'相被选为模型,以此类推。我们选择的用于判断模型好坏的标准是 AICC,该标准是取值越小起 时取得的 AICC 值最小。

那么,在被模型选入的自变量当中,到底哪些变量在模型当中更为重要,或者说哪些变量对因于 Predictor Improtance(预测变量重要性)视图。如图 9 所示:

图 9. 预测变量重要性视图

合作

Target: Cost of claim in thousands

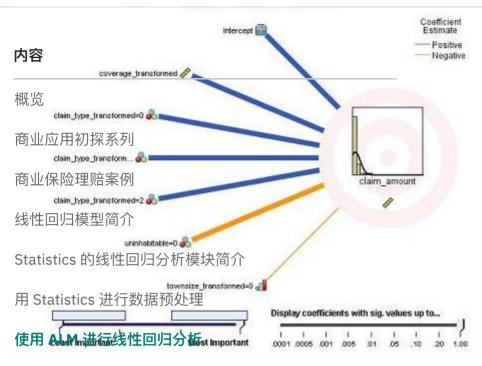


该规图按照变量的重要性进行了排序,重要性判断准则取值越大,柱状图越长,变量也越重要。 范围金额"是最重要的变量,"理赔类型"次之,而"居住城镇大小"的影响力是最小的。 评论

我们已经知道,多元线性回归模型主要是由线性表达式的回归系数确定的。下面,我们就来看数的取值。打开 Coefficients(系数)视图,如图 10 所示:

图 10. 系数视图的图表格式

合作



林爾市納達後数目可以看出,系数个数明显比变量个数多,对于包含有常数项和离散变量的模式 在多于变量个数。离散变量的取值不是连续的,而是分散、有限的几种类别,比如 Claim Type 将离散变量的每一种类别作为一个模型项,而将一个连续变量作为一个模型项,每个模型项都是 (保险责任范围金额)对应一条连线,理赔类型的三种类别对应三条连线(有一种类别模型项对应连线的粗细可以大致看出其显著性水平,显著性水平越高其连线越粗,在模型当中,模型项对应的变量的重要程度。蓝色的连线表明该系数为正值,说明该模型项与目标变量是正规 取值增大时目标变量取值也增大。而黄色的连线表明该系数为负值,与目标变量是负的线性关系

我们通过视图下方的下拉框,将该视图的显示格式从图表格式改变为表格式,如图 11 所示:

图 11. 系数视图的表格式

合作

	Model Term	Coefficient ►	Sig.	Importance
内容	Intercept	57.797	.000	
 既览	coverage_transformed	0.261	.000	0,315
`` 	claim_type_transformed=0	15,364	.000	0.263
可业 应用	初探系列 claim_type_transformed-1	125,197	.000	0.263
商业保险	里赔案例 transformed-2	137.226	.000	0.263
线性回归	claim_type_transfor Type of claim=Win 更重控 heft/Vandalism	rmed-3 d/Hail, 0*		0.263
tatistics	uninhabitable=0 的线性回归分析模	-121.737 块简介	.000	0.230
	uninhabitable=1	0*		0.230
刊 Statist	CS 进行数据预处理 townsize_transformed=0	-5.670	.073	0.193
吏用 ALM	进行线性图归分析	0*		0.193

*This coefficient is set to zero because it is redundant.

预测和输出模型

我们可以从系数的取值中分析出这些模型项与因变量之间的定量关系。比如"保险责任范围金部 袭铜当其他模型项的值不发生变化时,"保险责任范围金额"每增加 100(千元),因变量增加 的,理赔类型 2(污染物损害理赔)的系数值是 137.226,而理赔类型 3(风灾损害理赔)的系程关于题 3(风灾损害理赔)的系数值是 137.226,而理赔类型 3(风灾损害理赔)的系 离散变量的所有类别对应的模型项,总有一个模型项的系数取值为 0,作为比较其他类别的基次要此风灾损害理赔要高出 137.226(千元),是所有理赔类型当中理赔金额最高的。当然,所算出的估计值。

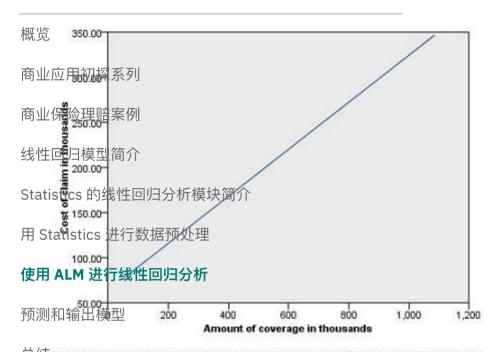
还有一种参考价值比较高的视图,是 Estimated Means(估计的平均值)视图,如图 12、图 1 著效应 (p<0.05) 的估计均值图表。这为我们提供了另一种视角,用直观的图形方式帮助我们分映的就是"保险责任范围金额"和"理赔金额"之间的关系。可以看出它们之间有着明显的线性关键金额较大的保单, 其理赔额度也更高。

图 12. 均值估计视图 - 保险责任范围金额与理赔金额

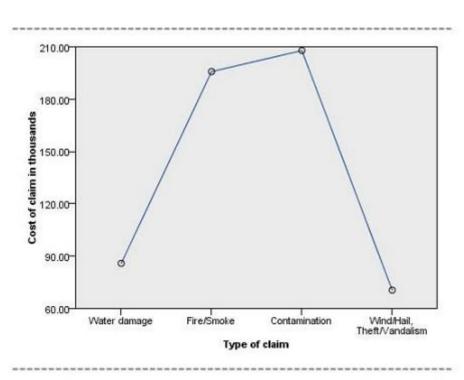
合作

Target: Cost of claim in thousands

内容 Estimated means charts for the top ten significant effects (p<.05) are displayed.



评论 图 13. 均值估计视图 - 理赔类型与理赔金额



以上就是模型浏览器当中一些主要的分析结果,它们用直观的图表描述了线性回归模型,提供们的决策提供有力的支持。

合作

內樹 拥有不同的建模方法,我们可以通过比较不同方法建立的模型,使我们对问题的分析更加 Subsets 方法来建模。

概览

如图 14 所示,重新打开 ALM 的对话框,选择 Build Option 页,在 Model Selection method(作商业应用初探系列。 Subsets(最佳子集)方法。在 Best Subsets Selection(最佳子集选择)区域当 中的 Criteria 推业保险地区例有"信息准则 AICC"、"调整后的 R2"和"过度拟合防止标准(ASE)"几种判断模。

候。 线性回归模型简介

图 14ti 沒 菁 優 傳 善 择 pest Aubsets



模型建好后,打开模型显示器当中的 Model Summary (模型概要)视图,如图 15 所示。

图 15. 模型概要视图 -Best Subsets

合作

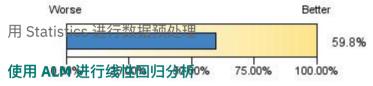
MOUEL SUITINALY

内容	Target	Cost of claim in thousands			
概览	Automatic Data Preparation	On			
商业	भारतिक इंटिएtion Method	Best Subsets			
商业	保险理赔案例 Information Criterion	39,889.155			

线性回偏標型領域 criterion is used to compare to models.

Models with smaller information criterion values fit better.

Statistics 的线性回归分析模块简介



预测和输出模型

Accuracy

图 16. 模型构建汇总视图 -Best Subsets

Model Building Summary Target: Cost of claim in thousands

		3 11	Medel								
		1	2	3	4	5	6	7	8	9	10
loform	ration Criterion	39,889,155	39,889,538	39,889.712	39,889.779	39,889.834	39,890,201	39,890.375	39,890.379	39,890.419	39,890.62
	uninhabitable	1	✓	1	1	1	1	1	1	1	1
	claim_type_transformed	1	V	✓	V	1	V	V	1	1	1
	townsize_transformed	1	1	1	1	1	1	1		1	1
	coverage_transformed	1	✓	1	✓	1	1	1	✓	✓	V
	retire		1				1				
Effect	Job_start_date_months		1		1		1	1			1
	primary_residence			1			1	1		1	
	Income_transformed					1				✓	
	policy_date_months										1
	occupancy date months										1

The model building method is Best Subsets using the Information Criterion, A checkmark means the effect is in the model.

合作

概览

线性回归模型简介 予**介)则未且输出模型** Statistics 的线性回归分析模块简介

如果要在原始数据超球管理赔金额的预测值,并和其原值进行比较,看模型拟合的好坏,可以是 Option (模型选项) 页面,如图 17 所示。选择"Save predicted values to dataset (将预测值保证用 ALM 进行线性回归分析

圈测和编出模式框 - 设置计算预测值和输出 PMML



这样,数据集视图当中会增加一列,显示计算出的理赔金额的预测值。如图 18 所示。

图 18. 计算出的预测值

合作

		marital	reside	docupancy_date	primary_residence	PredictedValue	民族	支量]
1	10	0	1	01/06/1978	1	169.25		
内容	10	0	1	02/04/1971	1	302.40		
A E	10	0	1	03/30/1977		-49.01		
4	10	1	3	05/23/1993	1	88.63		
- 5	10	0	1	09/04/2000	1	-32.92		
既览	10	1	2	04/05/1993	1	110.83		
7	10	0	- 1	09/02/2003	1	101.86		
8	10	- 1	2	08/17/1986	1	11.97		
संस् शिक्ष	·PH	初探系	石山 1	07/15/1968	1	149.15		
9141/7	10/1	计划术和	7 J 4	12/02/2000	1.	-34.22		
11	10	1	4	09/15/1999	1	73.25		
12.	10		2	08/12/1992	1	-35.52		
茍业份	和於	建赔案	例 2	08/02/1969	1	10.34		
14	Ю	1	3	01/04/1968	1	17.12		
15)0	- 1	2	12/02/1979	1	231.94		
半 性[-(ldi	模型简	介 2	07/19/1980	1	-8.67		
77	10		4	07/22/1968	1	197.54		
18	ю	0	1	03/01/1979	-1	-47.26		
19.:	10	~ 6/2 6/4 ³ IV	+15114/	\+C+## £924/2900\	1	139.67		
วเลูแร	MC	S 11/25/13	エピッコス	分析模块简介	1.	98.01		
21	10	1	2	01/18/1964	1	98.25		
22	10		4	08/25/1995	1	-32.66		
# Sta	Hile	tics i#4	一步打井子	カカトキ甲				10

地域で

运用 ALM 可以对商业保险公司的固定资产理赔案例进行详尽的分析。保险公司的服务中心采用测,能够减少理赔处理时间,提高了服务水平。ALM 建立的线性回归模型还可以提供很多信息金额影响更大,是积极的还是消极的影响,哪些理赔类型的理赔金额较高等等。有了这些分析纸取措施降低运营风险,提高效益。

ALM 可以被应用到商业、科研和教育领域等多个领域,有着十分广泛的应用。无论是专业用户科学准确的分析和预测,是一个功能强大,使用方便的建模和分析工具。

相关主题

- 访问 developerWorks Information Management 专区,了解信息管理相关的技术文章、在:
- 通过 IBM SPSS 软件家族预测分析模型的商业应用初探,第1部分:应用关联规则模型提高则模型来解决客户的具体商业问题——如何优化超市商品的摆放以提高销量。
- "数据挖掘产品 IBM SPSS Modeler 新手使用入门"(developerWorks 中国, 2011 年 3 月)
 用入门。

开发 学习 社区 **IBM Developer**

合作

• 随时关注 developerWorks 技术活动 和 网络广播。 内容

概览

评论

商业应用初探系列

添加或订阅评论, 请先登录或注册。

线性包括海轮贴提醒我

Statistics 的线性回归分析模块简介

IBM Developer

站点反馈

我要投稿

报告滥用

第三方提示

关注微博

大学合作

选择语言

English

中文

日本語

Русский

Português (Brasil)

Español

한글

Code patterns

技术文档库

软件下载

合作

订阅源

时事通讯

视频

博客

活动

社区

联系 IBM 隐私条约 使用条款 信息无障碍选项 反馈 Cookie 首选项